

距离测度加权采样的大实验更新版

从 NN-PR/TYPR 距离出发，决定 D-optimal 与随机采样的批次混合比例

实验规模	n=10000；p=20 和 p=50；5 类数据集；5 个 data seed；2 个初始采样 seed
策略数量	Measure-weighted、Random、D-optimal、Latin hypercube 共 4 组
批次设置	初始 5% 均匀 pilot；每轮新增 500 点；6 轮 batch 更新
主规则	使用 mean(d_FPR, d_TYPR) 作为保守距离，映射到 30%-95% 的 D-optimal 比例

核心结论 新的大实验表明，该测度最适合被解释为 transfer gate：距离小则更大胆迁移 PR/D-optimal 技术，距离大则保留更多随机探索。它不是万能地击败所有采样规则，但能揭示何时旧技术会产生负迁移。

1. 实验流程

实际应用中无法预先知道 NN 与 FullPR/TYPR 是否接近。因此实验先在训练集上做均匀 pilot 抽样，训练初始 NN，再计算该 NN 与 FullPR、TYPR 的响应曲面距离。距离经过归一化后转成下一批数据中的 D-optimal 比例。




图 1. 距离测度加权的批次采样流程

2. 实验设计

对每个数据集做 75/25 train/test 拆分，训练集内先均匀抽取 5% 作为 pilot subset。

用 pilot subset 训练单隐层 tanh NN；在 pilot validation 上计算 NN-FPR 和 NN-TYPR 距离。

主实验使用 $\text{mean}(d_FPR, d_TYPR)$ 而不是 $\min(\dots)$ ，避免高维下单个 PR 代理偶然贴近导致过度使用 D-optimal。

每轮固定新增 500 点，Measure-weighted 策略按 weight 混合 D-optimal 点和随机点；对照组为全随机、全 D-optimal 和 Latin hypercube。

3. 主结果

p	策略	Final MSE	相对随机提升	正提升率	运行数
20	Latin hypercube	0.004811	5.79%	76.0%	50
20	D-optimal	0.004986	4.11%	76.0%	50
20	Measure-weighted	0.004993	4.40%	72.0%	50
20	Random	0.005113	0.00%	0.0%	50
50	Latin hypercube	0.018574	0.17%	46.0%	50
50	Random	0.018808	0.00%	0.0%	50
50	Measure-weighted	0.019143	0.50%	54.0%	50
50	D-optimal	0.019594	-1.85%	48.0%	50




图 2. 不同维度下各策略相对随机采样的最终提升




图 3. 多轮 batch 更新中的相对随机提升曲线

4. 分数据集结果

Measure-weighted 在 $p=20$ 的多数结构上为正提升，在 $p=50$ 中能明显缓解全 D-optimal 的负迁移，尤其在 high-frequency 中将全 D-optimal 的大幅损失压回接近随机水平，在 local interior 中则取得最强结果。

p	数据集	Measure-weighted MSE	相对随机提升	正提升率
20	高频非多项式	0.010106	-9.52%	40.0%
20	局部内部结构	0.003893	5.82%	80.0%
20	二次多项式	0.007036	8.24%	90.0%
20	平滑非线性	0.002244	8.96%	90.0%
20	强非线性	0.001685	8.48%	60.0%
50	高频非多项式	0.022579	0.24%	60.0%
50	局部内部结构	0.008042	13.55%	80.0%
50	二次多项式	0.049157	-8.05%	30.0%
50	平滑非线性	0.010861	-2.91%	30.0%
50	强非线性	0.005076	-0.33%	70.0%




图 4. Measure-weighted 在各数据集和维度下的相对随机提升

5. 权重校准与测度解释

权重热图显示，采样比例不是按数据集标签硬编码，而是由每个 pilot run 的距离决定。p=20 中 high-frequency 被压到低 D-optimal 比例；p=50 中某些情形的权重明显下降，说明维度升高后 PR/TYPR 近似性变弱时，策略会自动更保守。

p	数据集	FPR 距离均值	TYPR 距离均值	D-optimal 比例均值
20	高频非多项式	0.22958	0.94323	0.323
20	局部内部结构	0.08290	0.90947	0.551
20	二次多项式	0.04888	0.92314	0.579
20	平滑非线性	0.01406	0.78233	0.779
20	强非线性	0.01903	0.80521	0.749
50	高频非多项式	0.01115	0.87244	0.377
50	局部内部结构	0.00287	0.69602	0.545
50	二次多项式	0.00381	0.67319	0.578

p	数据集	FPR 距离均值	TYPR 距离均值	D-optimal 比例均值
50	平滑非线性	0.00507	0.53331	0.694
50	强非线性	0.00797	0.42922	0.815




图 5. 由 NN-PR/TYPR 距离学习到的 D-optimal 平均比例

6. 敏感性与边界条件

重要修正 原先使用 min(d_FPR,d_TYPR) 时，p=50 的 Measure-weighted 相对随机为 -2.821%；改用 mean(d_FPR,d_TYPR) 后提高到 +0.501%，并超过全 D-optimal 的 -1.846%。这说明高维下需要更保守的距离组合规则。

- 优势：该测度能把采样策略从固定规则变成数据驱动规则，尤其能识别 D-optimal 可能负迁移的场景。
- 限制：Latin hypercube 在某些高频或全局覆盖需求强的场景仍然更稳定；当前策略只在随机和 D-optimal 之间混合，尚未把 Latin 作为可选动作。
- 后续改进：可把 D-optimal 下限从 30% 降到 10% 或引入三路混合（random / D-optimal / Latin），让远距离场景更接近纯探索。

7. 可写入论文的表述

本实验支持的不是“测度加权采样永远优于所有设计”，而是一个更稳健的结论：NN-PR/TYPR 距离可以作为旧 PR/D-optimal 技术迁移到新 NN 模型前的可操作 gate。距离小，旧技术可高比例迁移；距离大，策略保留随机探索以降低负迁移风险。